

Cadeias de Markov

Acoplamento

Teorema de Convergência

Referências:

- Häggström, *Finite Markov Chains*
- Brémaud, *Markov Chains - Gibbs Fields, Monte Carlo Simulation, Queues*, 2020, Springer

Convergência de cadeias de Markov

Objetivo:

Mostrar que, sob determinadas condições, a distribuição da cadeia de Markov num instante n grande estará “próxima” da distribuição estacionária, qualquer que seja a distribuição inicial.

Distância em variação total

Definição: distância em variação total

Sejam $\eta = (\eta_i; i \in S)$ e $\xi = (\xi_i; i \in S)$ duas distribuições de probabilidade em S , S enumerável. A **distância em variação total** entre η e ξ é definida por

$$d_V(\eta, \xi) = \frac{1}{2} \sum_{i \in S} |\eta_i - \xi_i|$$

Se X e Y são variáveis aleatórias, assumindo valores em S , com distribuições de probabilidade η e ξ , respectivamente, denota-se também

$$d_V(\eta, \xi) = d_V(X, Y)$$

Distância em variação total - resultado

Lema

Sejam $\boldsymbol{\eta} = (\eta_i; i \in S)$ e $\boldsymbol{\xi} = (\xi_i; i \in S)$ duas distribuições de probabilidade em S , S enumerável.

$$d_V(\boldsymbol{\eta}, \boldsymbol{\xi}) = \frac{1}{2} \sum_{i \in S} |\eta_i - \xi_i| = \sup_{A \subseteq S} |\boldsymbol{\eta}(A) - \boldsymbol{\xi}(A)|$$

Para X e Y variáveis aleatórias no mesmo espaço de estados S , tem-se que

$$d_V(X, Y) = \sup_{A \subseteq S} |P(X \in A) - P(Y \in A)|$$

Prova: ver Brémaud - Lema 4.1.2

Convergência em variação total

Convergência em variação total - definição

Se $\xi^{(1)}, \xi^{(2)}, \dots$ e η são distribuições de probabilidade em S , dizemos que $\xi^{(n)}$ **converge para** η **em variação total** quando $n \rightarrow \infty$ se

$$\lim_{n \rightarrow \infty} d_V(\xi^{(n)}, \eta) = 0$$

Notação: $\xi^{(n)} \xrightarrow{\text{var. total}} \eta$

Seja $\{X_n\}_{n \geq 0}$ um processo estocástico em S . Dada uma distribuição π em S , dizemos que o processo $\{X_n\}$ **converge em variação total** para π se

$$\lim_{n \rightarrow \infty} \sum_{i \in S} |P(X_n = i) - \pi_i| = 0$$

Convergência de cadeias de Markov

Teorema 3

Seja $\mathbf{X} = \{X_n\}$ uma cadeia de Markov **irredutível recorrente positiva e aperiódica** com espaço de estados enumerável S , matriz de probabilidades de transição \mathbf{P} , distribuição **inicial arbitrária** $\nu^{(0)}$ e distribuição estacionária π . Então,

$$\nu^{(0)} \mathbf{P}^n \xrightarrow{\text{var. total}} \pi \quad \text{quando} \quad n \rightarrow \infty$$

Interpretação:

Se a cadeia for irredutível recorrente positiva e aperiódica, então para qualquer que seja a distribuição inicial, a distribuição do processo num instante n grande estará próxima da distribuição estacionária.

Dizemos, nesse caso, que a cadeia de Markov está se aproximando do **equilíbrio** quando $n \rightarrow \infty$.

Demonstração do Teorema de Convergência

O teorema de convergência (Teorema 3) vale para S enumerável (finito ou infinito). No entanto, a demonstração será feita para o caso em que S é **finito**. Será feita NA LOUSA.

A demonstração para o caso infinito é similar, com detalhes adicionais para lidar com somas infinitas.

Passos:

- (1) Para cadeia de Markov irreduzível recorrente positiva e **aperiódica**, existe $M < \infty$ tal que $P^{(M)}$ é uma matriz ergódica (todas as entradas/células são estritamente positivas) \longrightarrow ver Proposição
- (2) Usar **acoplamento**
Ver desenho na lousa
- (3) Mostrar que o **tempo de acoplamento** é finito
- (4) Relacionar tempo de acoplamento com a distância de variação total

Proposição

Ergodicidade da matriz de transição

Seja $\mathbf{X} = \{X_n\}$ uma cadeia de Markov irreduzível recorrente positiva e aperiódica com espaço de estados S e matriz de probabilidades de transição \mathbf{P} .

Então existe um inteiro positivo $M < \infty$, tal que $p_{ij}^{(M)} > 0$ para todo $i, j \in S$.

Prova: ver Teorema 2.3.10 - Brémaud (com $d = 1$).

Defina

$$\alpha = \inf\{p_{ij}^{(M)} : i \in S\}$$

e note que, a partir da Proposição acima, $\alpha > 0$.